Углубленное программирование на языке C / C++

Лекция № 1

Алексей Петров

Обзор курса. Модуль №1

Модуль №1. Углубленное программирование на языке С. Управление памятью

- **Лекция №1.** Цели и задачи курса. Организация и использование оперативной памяти в программах на языке С
- **Практикум №1.** *Адресная арифметика. Одно- и многомерные массивы и строки. Алгоритмы их обработки*
- **Лекция №2.** Организация и использование сверхоперативной памяти. Основы многопоточного программирования. Вопросы качества структурного программного кода
- **Практикум №2.** *Составные типы языка С. Алгоритмы их обработки. Взаимодействие с ОС*

Обзор курса. Модуль №2

Модуль №2. Объектная модель языка C++. Обобщенное и безопасное программирование

- **Лекция №3.** Основные вопросы объектно-ориентированного программирования (ООП) на языке C++
- **Лекция №4.** Дополнительные вопросы ООП на языке C++. Динамическая идентификация типов (RTTI)
- **Практикум №3.** *Проектирование полиморфной иерархии классов повышенного уровня сложности*
- **Лекция №5.** Шаблоны классов и методов. Обработка исключительных ситуаций. Обобщенное и безопасное программирование
- **Практикум №4.** *Разработка и обеспечение безопасности полиморфной иерархии с шаблонами классов*

Обзор курса. Модуль №3

Модуль №3. Библиотеки для промышленной разработки ПО: STL, Boost

- **Лекция №6.** Практическое введение в STL
- **Лекция №7.** Функциональное программирование в C++11. Практическое введение в Boost
- **Практикум №5.** *Оптимизация полиморфной иерархии классов с использованием элементов библиотек STL и Boost*

Обзор курса. Модуль №4

Модуль №4. Шаблоны ОО-проектирования. Основы промышленной разработки ПО

- **Лекция №8.** Принципы и шаблоны объектно-ориентированного проектирования. Базовые шаблоны, шаблоны GoF
- **Практикум №6.** *Оптимизация полиморфной иерархии классов с использованием шаблонов объектно-ориентированного проектирования однопоточных приложений*
- **Лекция №9.** Идиоматика C++. Основы рефакторинга и качество исходного кода. Стандарты кодирования и методологии разработки ПО
- **Практикум №7.** *Инспекция и рефакторинг объектно-ориентированного исходного кода*

Лекция №1. Цели и задачи курса. Организация и использование ОЗУ и СОЗУ в программах на языке С

1. Цели, задачи, структура курса.
   Язык С в современной промышленной разработке.
2. Организация оперативной памяти. Одно- и многомерные массивы, строки и указатели.
3. Выравнивание и упаковка переменных простых и составных типов.
4. Выделение и освобождение памяти, управление памятью и производительность кода.
5. Стандарт POSIX и переносимый исходный код.
6. Оптимизация работы с кэш-памятью ЦП ЭВМ.
7. **Постановка ИЗ к практикуму №1.**

Цель и структура курса

Цель курса — сформировать практические навыки и умения, необходимые специалистам по разработке ПО UNIX-подобных операционных систем (ОС) для участия в проектах **промышленной разработки** среднего уровня сложности, в том числе для замещения стажерских должностей разработчиков **серверной части высоконагруженных приложений**.

Состав курса (весна 2014 / 2015 уч. г.) — 9 лекций, 7 практикумов.

Для сравнения:

- осень-весна 2013 / 2014 — 9 лекций, 7 практикумов;
- весна 2013 — 10 лекций, 6 практикумов;
- осень 2012 — 12 лекций, 4 практикума.

Общая аудиторная нагрузка — 64 акад. часа (лекции — 36 акад. часов, практика — 28 акад. часов).

Чему научимся?
Практический результат (1 / 2)

Обязательно:

- моделировать систему при помощи **UML-диаграмм**;
- разрабатывать код на языке C / C++ с элементами **C++1y**;
- использовать инструменты анализа кода: **Valgrind**, **dwarves** и др.;
- создавать качественный код в **структурной и объектно-ориентированной парадигме**;
- использовать приемы **обобщенного и безопасного программирования**;
- применять промышленные библиотеки **STL, Boost**;
- внедрять в продукт классические архитектурные **шаблоны GoF;**
- оценивать **качество** и выполнять **рефакторинг** исходного программного кода;
- презентовать и защищать свои разработки перед аудиторией.

Чему научимся?
Практический результат (2 / 2)

По желанию:

- моделировать **варианты использования** продукта;
- проектировать и реализовывать слой данных продукта;
- выполнять **кодогенерацию** по UML-моделям;
- писать **многопоточные** приложения;
- создавать **POSIX**-совместимый **переносимый** исходный код;
- реализовывать графический интерфейс пользователя в **Qt**;
- использовать систему контроля версий: **Git** или аналогичную.

Организационные положения

Расписание занятий:

- постановка задач к практикумам — через блог дисциплины и на лекциях №№1, 2, 3, 4, 6, 8 и 9 (работа выполняется индивидуально и в группах!).

Правила поведения и регламент:

- приходить вовремя, самостоятельно проходить электронную регистрацию;
- общезначимые вопросы задавать во время пауз преподавателя или по поднятию руки, индивидуальные — в перерыве или после занятия;
- средства связи и ноутбуки использовать только в беззвучном режиме или режиме текстовых сообщений;
- продолжительность занятий — 4 акад. часа с 1 или 2 перерывами общей продолжительностью до 10 минут.

Знакомство с аудиторией:

- известные языки программирования (C, C++, Java);
- опыт разработки, известные среды и технологии.

Web-ресурсы и онлайн-книги

- Официальный Web-сайт проекта Boost: http://www.boost.org/.
- Официальный Web-сайт проекта Eclipse: http://www.eclipse.org/.
- Официальный Web-сайт проекта Qt: http://qt-project.org/.
- Справка по языкам C / C++: http://en.cppreference.com/w/.
- C Programming: http://en.wikibooks.org/wiki/C_Programming.
- Google C++ Style Guide: http://google-styleguide.googlecode.com/svn/trunk/cppguide.xml
- More C++ Idioms: http://en.wikibooks.org/wiki/More_C%2B%2B_Idioms.
- Schäling, B. *The Boost C++ Libraries*: http://en.highscore.de/cpp/boost/.
- Stack Overflow — http://stackoverflow.com/.
- Standard C++ — http://isocpp.org/.
- The C++ Resources Network — http://www.cplusplus.com/.

Блог дисциплины

- **Размещен** по адресу: https://tech-mail.ru/blog/cpp/
- **Что делать:**
  - подписаться на обновления;
  - изучить более ранние записи;
  - задавать вопросы;
  - участвовать в опросах и обсуждениях.

Рекомендуемая литература: модуль №1

- Керниган Б., Ритчи Д. Язык программирования C. — Вильямс, 2012. — 304 с.
- Прата С. Язык программирования C. Лекции и упражнения. — Вильямс, 2013. — 960 с.
- Шилдт Г. Полный справочник по C. — Вильямс, 2009. — 704 с.
- Butenhof, D. *Programming with POSIX Threads* (Addison-Wesley, 1997).
- Fog, A. Optimizing Software in C++: An Optimization Guide for Windows, Linux and Mac platforms (Oct. 2013). URL: http://www.agner.org/optimize/optimizing_cpp.pdf.
- Intel® 64 and IA-32 Architectures Optimization Reference Manual (July 2013). URL: http://www.intel.com/content/dam/www/public/us/en/documents/manuals/64-ia-32-architectures-optimization-manual.pdf.
- King, K. C Programming: A Modern Approach, 2nd ed. (W. W. Norton & Co., 2008).
- Meyers, S. CPU Caches and Why You Care. URL: http://aristeia.com/TalkNotes/PDXCodeCamp2010.pdf.

Язык C сегодня

- **2015** — активное применение языка в практике программирования:
  - ядра ОС: Linux, Microsoft Windows NT, IBM z/OS
  - инструментальные средства: GDB The GNU Project Debugger, Vim, gedit
  - системы управления БД и Web-серверы и пр.: MySQL, Oracle Database, NGINX™
  - проекты Mail.Ru Group: tarantool, Почта@Mail.Ru и пр.
- В феврале 2015 г. TIOBE Programming Community Index языка C составляет 16,488% (1-е место), а сам язык в нем занимает 1 – 2-е места с 1989 г. (конкурируя, главным образом, с Java).

TIOBE SOFTWARE THE CODING STANDARDS COMPANY

Вопросы управления памятью и производительность кода: зачем?

Неоптимальная работа с памятью становится **ограничивающим фактором** для большинства программ.

Проблему усугубляет **рост сложности подсистемы памяти**, в частности — механизмов кэширования и пр.

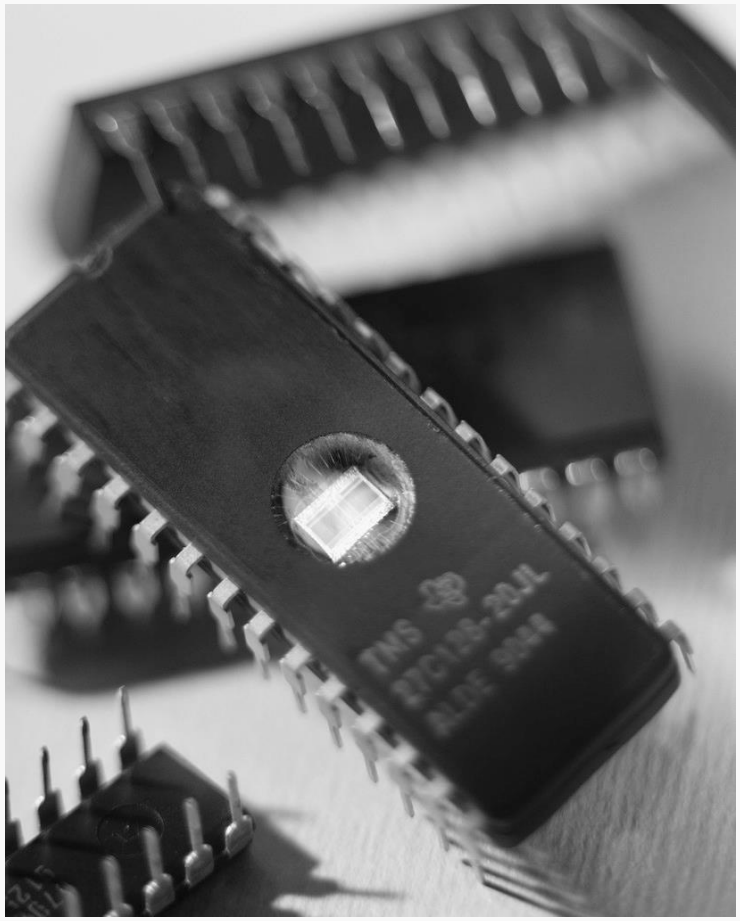

Модели управления памятью и области видимости объектов данных

- Предлагаемые языком C модели управления объектами данных (переменными) закреплены в понятии класса памяти, которое охватывает:
  - **время жизни** — продолжительность хранения объекта в памяти;
  - **область видимости** — части исходного кода программы, из которых можно получить доступ к объекту по идентификатору;
  - **связывание** — части исходного кода, способные обращаться к объекту по его имени.
- Для языка C характерны **три области видимости**:
  - **блок** — фрагмент кода, ограниченный фигурными скобками (напр. составной оператор), либо заголовок функции, либо заголовок оператора for, while, do while и if;
  - **прототип функции**;
  - **файл**.

Классы памяти в языке C

Класс памяти	Время жизни	Область видимости	Тип связывания	Точка определения
Автоматический	Автоматическое	Блок	Отсутствует	В пределах блока, опционально `auto`
Регистровый	Автоматическое	Блок	Отсутствует	В пределах блока, `register`
Статический, без связывания	Статическое	Блок	Отсутствует	В пределах блока, `static`
Статические, с внешним связыванием	Статическое	Файл	Внешнее	Вне функций
Статические, с внутренним связыванием	Статическое	Файл	Внутреннее	Вне функций, `static`

Размещение объектов данных на регистрах процессора

- Применение ключевого слова register для активно используемых переменных:
  - несет все риски «ручной оптимизации» кода и полезно преимущественно для встроенных систем и архитектур, не имеющих компиляторов C с долгой историей (gcc разрабатывается с 1987 г.);
  - относится к регистрам ЦП (в x86/x86-64: AX, EBX, RCX и т.д.), но не кэш-памяти ЦП 1-го или 2-го уровня;
  - является рекомендацией, но не требованием к компилятору;
  - вполне может игнорироваться компилятором, который будет действовать «на свое усмотрение» (например, разместит переменную на регистре, потребность в котором возникнет позднее всего).
- **Операция взятия адреса переменной** со спецификатором register **недопустима** вне зависимости от того, размещена ли она фактически на регистре.

Операция sizeof и тип size_t

- **Унарная операция** sizeof:
  - допускает скобочную и бесскобочную (только для переменных) нотацию: sizeof a или sizeof(T);
  - возвращает объем памяти, выделенной под объект простого или составного типа, в байтах как значение переносимого типа size_t, являющегося псевдонимом одного из базовых беззнаковых целых типов (ср. int32_t и пр.);
  - не учитывает возможного выравнивания объекта.
- Использование вычисляемых компилятором конструкций вида sizeof(T) не влияет на производительность кода, но **повышает переносимость.**

Указатели и арифметика указателей. Тип ptrdiff_t

- Стандартные указатели типа T* как составной тип языка C и символический способ использования адресов можно условно считать «шестым классом памяти», важной особенностью которого является поддержка специфической арифметики.
- Пусть p, p2 — указатели типа T*, а n — значение целого типа (желательно — ptrdiff_t). Тогда:
  - p + n либо n + p — адрес, смещенный относительно p на n единиц хранения размера sizeof(T) в направлении увеличения адресов;
  - p – n — адрес, смещенный относительно p на n единиц хранения размера sizeof(T) в направлении уменьшения адресов;
  - p++ либо ++p, p-- либо --p — аналогичны p + 1 и p – 1;
  - p – p2 — разность содержащихся в указателях адресов, выраженная в единицах хранения и имеющая тип ptrdiff_t. Разность положительна при условии, что p расположен в пространстве адресов «правее» p2.

Одномерные массивы (строки)

- **Для одномерного массива `T a[N]` в языке C справедливо:**
  - массивы поддерживают полную и частичную инициализацию, в том числе с помощью выделенных инициализаторов;
  - в частично инициализированных массивах опущенные значения трактуются как нули;
  - элементы массивов размещаются в памяти непрерывно и занимают смежные адреса, для обхода которых может использоваться арифметика указателей;
  - строки `char c[N]` конструктивно являются частными случаями массивов, при этом в корректных строках `c[sizeof(c) – 1] == '\0'`;
  - `sizeof(a)` возвращает размер массива в байтах (не элементах!);
  - `sizeof(a[0])` возвращает размер элемента в байтах.
- **Принятая система обозначения массивов является лишь особым способом применения указателей.**

Одномерные массивы (строки): пример


```
// с освобождением квадратных скобок
int a[] = {1, 2, 3};
// эквивалентно int a[3] = {1, 2, 3};

// с частичной неявной инициализацией
int b[5] = {1, 2, 3};
// эквивалентно:
// int b[5] = {1, 2, 3, 0, 0};

// с выделенными инициализаторами
int c[7] = {1, [5] = 10, 20, [1] = 2};
// эквивалентно:
// int c[7] = {1, 2, 0, 0, 0, 10, 20};
```

Одномерные массивы (строки) и указатели

- Пусть T a[N] — массив. Тогда:
  - имя массива является **константным указателем на 0-й элемент**: a == &a[0];
  - для любых типов и длин массивов **справедливо**: &a[i] == a + i и a[i] == *(a + i);
- С учетом этого эквивалентны прототипы:
  - int foo(double [], int);
  - int foo(double *, int);
- Передать массив в функцию можно так, как показано выше, или как **пару указателей: на 0-й и N-й элементы** (обращение к элементу a[N] без его разыменования допустимо):
  - int foo(double *, double *);

Макроопределение NULL

- Стандартное макроопределение NULL расширяется препроцессором до константы с семантикой **«пустого» указателя**, который…
  - является константным целочисленным выражением, вычисляемым в длинный или короткий нуль (0L или 0), либо
  - выступает как результат приведения такого значения к void* (напр. (void*)0).
- Значение NULL приводимо к любому типу-указателю и может использоваться в конструкциях вида:
  - if (p != NULL) // …
  - if (q == NULL) // …

Вопросы безопасного программирования

- **Инициализировать указатели** во время определения:
  - допустимый адрес;
  - 0, (void*)0 или NULL.
- **Проверять:**
  - значения указателей перед их разыменованием;
  - значения индексов элементов массивов перед использованием;
  - возвращаемые значения стандартных функций после их вызова.

Стандартные функции ввода-вывода

Имя функции	Назначение функции	Причины ошибок	POSIX-совместима?
`int scanf(const char *restrict format, ... );`			
`scanf`	Осуществляет форматный ввод с консоли — чтение из стандартного входного потока `stdin`. Возвращает количество успешно считанных элементов ввода	Некорректная входная последовательность (EILSEQ) Недостаточно аргументов (EINVAL)	Да
`int printf(const char *restrict format, ...);`			
`printf`	Осуществляет форматный вывод в консоль — запись в стандартный выходной поток `stdout`. Возвращает количество переданных в поток байт	EILSEQ, EINVAL и др.	Да

Стандартные функции для работы с динамической памятью (1 / 2)

Имя функции	Назначение функции	Причины ошибок	POSIX-совместима?
void *malloc(size_t size);			
malloc	Выделяет неиспользуемый участок памяти объекту данных размера size байт, не меняя содержимое указанного участка	Недостаточно памяти (ENOMEM)	Да
void *calloc(size_t nelem, size_t elsize);			
calloc	Выделяет неиспользуемый участок памяти массиву из nelem элементов размера elsize байт каждый и выполняет его поразрядное обнуление	Недостаточно памяти (ENOMEM)	Да

Стандартные функции для работы с динамической памятью (2 / 2)

Имя функции	Назначение функции	Причины ошибок	POSIX-совместима?
`void *realloc(void *ptr, size_t size);`			
`realloc`	Изменяет размер объекта данных, на который указывает `ptr`, до `size`. Если указатель `ptr` пуст, вызов эквивалентен `malloc`. Если `size == 0`, память под объектом освобождается	Недостаточно памяти (ENOMEM)	Да
`void free(void *ptr);`			
`free`	Вызывает освобождение памяти, на которую указывает `ptr`, делая ее доступной для нового выделения. Дальнейшее использование `ptr` влечет неопределенное поведение	Нет	Да

Выравнивание объектов, размещаемых статически. GCC-атрибут aligned (1 / 2)

- Одним из способов повышения производительности программы является такое размещение данных в ОЗУ, при котором они эффективно загружаются в кэш-память ЦП. Для этого данные должны быть, как минимум, **выровнены на границу линии кэш-памяти данных 1-го уровня (L1d)**. Выравнивание объекта в ОЗУ обычно определяется характеристиками выравнивания, которые имеет соответствующий тип данных. При этом:
  - выравнивание **скалярного объекта** определяется собственной характеристикой выравнивания приписанного ему базового типа;
  - выравнивание **массива**, — если размер каждого элемента не кратен величине выравнивания, — распространяет свое действие только на элемент с индексом 0;
  - выравнивание объектов в программе на языке C может регулироваться **на уровне отдельных переменных и типов данных.**, для чего в компиляторе GCC служит атрибут aligned.

Выравнивание объектов, размещаемых статически. GCC-атрибут aligned (2 / 2)

- Выравнивание статически размещаемых переменных имеет силу как для глобальных, так и для автоматических переменных. При этом характеристика выравнивания, присущая типу объекта, полностью игнорируется.
- При выравнивании массивов гарантированно выравнивается только начальный, нулевой элемент массива.

Выравнивание объектов, размещаемых статически. Атрибут aligned: пример


```
// выравнивание, регулируемое на уровне объекта
// переменная qwd выравнивается на границу 64 байт
uint64_t qwd __attribute((aligned(64)));

// выравнивание, регулируемое на уровне типа
// переменные типа al128int_t (синоним int)
// выравниваются на границу 128 байт
typedef  int __attribute((aligned(128))) al128int_t;
al128int_t aln;
```

Выравнивание объектов, размещаемых динамически. Функция posix_memalign

- Функция **posix_memalign**:
  - определена в стандарте POSIX 1003.1d;
  - имеет прототип
    `int posix_memalign(void **memptr, size_t alignment, size_t size);`
  - выделяет неиспользуемый участок памяти размера size байт, выровненный на границу alignment, и возвращает указатель на него в memptr;
  - допускает освобождение выделенной памяти функцией free().
- Требования к значению **alignment**:
  - кратно sizeof(void*);
  - является целочисленной степенью числа 2.
- **Ошибки (EINVAL, ENOMEM):**
  - значение alignment не является кратной sizeof(void*) степенью 2;
  - недостаточно памяти.

posix_memalign: пример (1 / 2)


```
int b[7] = {1, [5] = 10, 20, [1] = 2}; // массив-источник
int *p = NULL,                         // массив-приемник
    errflag;                    // код ошибки posix_memalign

// установить размер линии кэш-памяти данных 1-го уровня
// (L1d); типичное значение: 64 байта
long l1dcls = sysconf(_SC_LEVEL1_DCACHE_LINESIZE);
// проверить, удался ли вызов sysconf()
if (l1dcls == -1)
// если вызов sysconf() неудачен, использовать значение
// выравнивания по умолчанию
        l1dcls = sizeof(void*);
```

posix_memalign: пример (2 / 2)


```
// выделить память с выравниванием на границу строки L1d
errflag = posix_memalign((void**)&p, l1dcls, sizeof b);
if(!errflag)// в случае успеха posix_memalign возвращает 0
{
        printf("\nL1d cache line size is %ld\n", l1dcls);
        printf("p and &p are %p and %p\n", p, &p);
        p = memcpy(p, b, sizeof(b));
        // ...
        free(p);
}
else
        printf("posix_memalign error: %d\n", errflag);
```

Многомерные массивы

- **Двумерный массив** — объект данных T a[N][M], который:
  - содержит N последовательно расположенных в памяти строк по M элементов типа T в каждой;
  - в общем и целом инициализируется аналогично одномерным массивам;
  - по характеристикам выравнивания идентичен объекту T a[N * M], что сводит его двумерный характер к удобному умозрительному приему, упрощающему обсуждение и визуализацию порядка размещения данных.
- Массивы размерности больше двух считаются **многомерными**, при этом (N + 1)-мерные массивы индуктивно определяются как линеаризованные массивы N-мерных массивов, для которых справедливо все сказанное об одно- и двумерных массивах.

Многомерные массивы: пример


```
// определение двумерных массивов
int a[2][3] = {
        {0, 1},         // частичная инициализация строки
        {2, 3, 4}};     // полная инициализация строки
int b[2][3] = {0, 1, 2, 3, 4};

// результаты:
// a: {0, 1, 0, 2, 3, 4}; b: {0, 1, 2, 3, 4, 0}

// определение массивов размерности больше 2
double d[3][5][10];
int32_t k[5][4][3][2];
```

Многомерные массивы и указатели

- Для многомерных массивов справедлив ряд тождеств, отражающих эквивалентность соответствующих выражений языка C. Так, для двумерного массива `T a[N][M]` справедливо:
  - `a == &a[0]; a + i == &a[i]`;
  - `*a = a[0] == &a[0][0]`;
  - `**a == *&a[0][0] == a[0][0]`;
  - `a[i][j] == *(*(a + i) + j)`.
- Использование операции разыменования * не имеет каких-либо преимуществ перед доступом по индексу, и наоборот. Трансляция и первой, и второй формы записи в объектный код приводит в целом к одинаковым результатам.

Многомерные массивы и указатели: пример


```
// указатели на массивы и массивы указателей
int k[3][5];
int (*pk)[5];  // указатель на массив int[5]
int *p[5];     // массив указателей (int*)[5]

// примеры использования (все – допустимы)
pk       = k;  // аналогично: pk = &k[0];
pk[0][0] = 1;  // аналогично: k[0][0] = 1;
*pk[0]   = 2;  // аналогично: k[0][0] = 2;
**pk     = 3;  // аналогично: k[0][0] = 3;
```

Совместимость указателей

- Общеизвестно, что для любого конкретного типа T, не тождественного ему типа Y и указателей T *pt и Y *py недопустимо присваивание:

```
pt = py; // T – не void
```

- Представленный пример является частным случаем более общего правила совместимости указателей, расширением которого является запрет на присваивание значения указателя на константу «обычному» указателю.

Совместимость указателей: пример


```
// определения
double *pd, **ppd;
double (*pda)[2];
double dbl32[3][2];
double dbl23[2][3];
// допустимые примеры использования
pd  = &dbl32[0][0];    // double* -> double*
pd  = dbl32[1];        // double[] -> double*
pda = dbl32;           // double(*)[2] -> double(*)[2]
ppd = &pd;             // double** -> double**
// недопустимые примеры использования
pd  = dbl32;           // double[][] -> double*
pda = dbl23;           // double(*)[3] -> double(*)[2]
```

Указатели на константы и константные указатели

- Различное положение квалификатора const в определении указателя позволяет вводить в исходном коде программ четыре разновидности указателей:
  - «обычный» указатель (вариант 1) — изменяемый указатель на изменяемую через него область памяти;
  - указатель на константу (вариант 2) — изменяемый указатель на неизменяемую через него область памяти;
  - константный указатель (вариант 3) — неизменяемый указатель на изменяемую через него область памяти;
  - константный указатель на константу (вариант 4) — неизменяемый указатель на неизменяемую через него область памяти.

Указатели на константы и константные указатели: пример


```
// пример 1: определения
int *p1;                // обычный указатель
const int *pc2;         // указатель на константу
int *const cp3;         // константный указатель
const int *const cpc4; // константный указатель на константу

// пример 2: совместимость T*, const T* и const T**
int             *pi;
const int       *pci;
const int       **ppci;
pci  = pi;  // допустимо:   int* -> const int*
pi   = pci; // недопустимо: const int* -> int*
ppci = &pi; // недопустимо: int** -> const int**
```

Указатели и квалификатор restrict

- Использование ключевого слова restrict допустимо **строго в отношении указателей** и…
  - расширяет возможности компилятора по оптимизации некоторых видов кода путем поиска сокращенных методов вычислений;
  - означает, что указатель — **единственное** (других нет) **исходное** (первоначальное) **средство доступа** к соответствующему объекту.
- В отсутствие квалификатора restrict компилятор вынужден прибегать к «пессимистичной» стратегии оптимизации.
- Квалификатор restrict широко применяется в отношении формальных параметров функций стандартной библиотеки языка C. Например:
  - void *memcpy(void *restrict *s1*, const void *restrict *s2*, size_t *n*);
  - int sscanf(const char *restrict s, const char *restrict *format*, …);

Указатели и квалификатор restrict: пример


```
// restrict: оптимистичная стратегия
int *restrict a = (int*)malloc(N * sizeof(int));
a[k] *= 2;              // (1)
// здесь следует иной код без участия a[k]
a[k] *= 3;              // (2)
// строки (1) и (2) вкупе эквивалентны: a[k] *= 6;

// пессимистичная стратегия
double d[N];   // d – не единственное средство доступа
double *p = d; // p – не исходное средство доступа (см. d)
d[k] *= 2;     // (3)
// здесь следует иной код без участия d[k]
d[k] *= 3;     // (4)
// стр. (3) и (4) не могут быть объединены ввиду существ. p
```

Многомерные массивы и функции

- **В общем случае** для передачи функции двумерного массива T a[N][M] используется формальный параметр T **pa. При этом информация о размерности массива закреплена **в типе** (T**), а размеры передаются как **дополнительные параметры**.
- Существование в языке объектов вида T (*pt) [M] открывает возможность **встраивания** информации о длине строк массива в тип данных и определения функций с прототипами вида:
  - void foo(T a[][M], size_t N);
  - void foo(T (*a)[M], size_t N); // комплект [] трактуется как указатель
- Для многомерных массивов аналогично имеем:
  - void bar(T b[][SZ2][SZ3][SZ4], size_t sz1);
  - void bar(T (*b)[SZ2][SZ3][SZ4], size_t sz1);

Массивы переменной длины (1 / 2)

- **Массивы переменной длины** — введенное в стандарте C99 языковое средство **динамического** (а не традиционно статического) распределения локальной памяти функций. Размеры таких массивов по каждому измерению остаются **неизвестными** до момента исполнения кода функции:
  - концепция массивов переменной длины (VLA, variable-length array) — ответ разработчиков C99 на требование научного сообщества обеспечить переносимость на язык C наработанной десятилетиями базы на языке FORTRAN, более гибком в части работы функций с массивами.
- Размер массива переменной длины:
  - **определяется переменными** (отсюда название);
  - **остается постоянным** до уничтожения объекта.

Массивы переменной длины (2 / 2)

- С учетом ограничений C99 массивы переменной длины:
  - предполагают использование класса автоматической памяти;
  - определяются внутри блоков и прототипов функций;
  - не допускают инициализации при создании.
- Идентификатор массива переменной длины, как и традиционного массива, является **указателем**.
- Использование массива переменной длины как формального параметра функции означает передачу данных **по указателю**.

Массивы переменной длины: пример


```
// прототип функции
int foo(size_t rows, size_t cols, double a[rows][cols]);
int foo(size_t, size_t, double a[*][*]); // имена опущены
// определение функции
int foo(size_t rows, size_t cols, double a[rows][cols])
{ /* ... */ }

int bar()
{
    int n = 3, m = 4;
    int var[n][m];    // массив как локальная переменная
    // ...
}
```

Упаковка переменных составных типов (1 / 2)

- Для структур данных актуален также не характерный для массивов и скаляров вопрос **упаковки данных**, обусловленный наличием у элементов структур индивидуальных характеристик выравнивания.
- **Проблема упаковки структур** заключается в том, что смежные (перечисленные подряд) элементы часто физически не «примыкают» друг к другу в памяти.

Упаковка переменных составных типов (2 / 2)

- Например (для x86):

```
typedef struct {
    int          id;            //  4 байта
    char         name[15];      // 15 байт
    double       amount;        //  8 байт
    _Bool        active;        //  1 байт
} account;                  // 28 байт (не 32 байта!)
```

- Наличие лакун, аналогичных выявленным 4-байтовым (13%) потерям в структуре account, вызывается совокупностью факторов:
  - архитектура процессора (напр., x86 или x86-64);
  - оптимизирующие действия компилятора;
  - выбранный программистом порядок следования элементов.

Реорганизация структур данных: рекомендации

- Реорганизация структур для повышения эффективности использования кэш-памяти должна идти **по 2 направлениям**:
  - декомпозиция тяжеловесных («божественных») структур на более мелкие, узкоспециализированные структуры, которые при решении конкретной задачи используются полностью либо не используются вообще;
  - устранение в структурах лакун, обусловленных характеристиками выравнивания типов их элементов (см. ранее).
- **При прочих равных условиях крайне желательно:**
  - переносить наиболее востребованные элементы структуры к ее началу (при загрузке в кэш-память такие элементы структуры могут становиться «критическими словами», доступ к которым должен быть самым быстрым);
  - обходить структуру в порядке определения элементов, если иное не требуется задачей или прочими обстоятельствами.

Реорганизация структур данных: рекомендации: пример


```
typedef struct { // вар. 1: 28/32 байт (x86: 13% потерь)
    int          id;            //  4 байта
    char         name[15];      // 15 байт
    /* лакуна — 1 байт выравнивания */
    double       amount;        //  8 байт
    _Bool        active;        //  1 байт
    /* лакуна — 3 байта выравнивания */
} account_1;                    // 32 байта
typedef struct { // вар. 2: 28/28 байт (x86: 0% потерь)
    int          id;            //  4 байта
    char         name[15];      // 15 байт
    _Bool        active;        //  1 байт
    double       amount;        //  8 байт
} account_2;                    // 28 байт
```

Реорганизация структур данных: недостатки и альтернатива решения

- Недостатки реорганизации:
  - снижение удобства чтения и сопровождения исходного кода;
  - риск размещения совместно используемых элементов (напр., длины вектора и адреса его начального элемента) на разных линиях кэш-памяти.
- Основная альтернатива реорганизации — замена стихийно выбранных типов данных наиболее адекватными по размеру, вплоть до использования битовых полей данных.

Кэш-память в архитектуре современных ЭВМ

- **Проблема** — отставание системной шины [и модулей оперативной памяти (DRAM)] от ядра ЦП по внутренней частоте; простой ЦП.
- **Решение** — включение в архитектуру небольших модулей сверхоперативной памяти (SRAM), полностью контролируемой ЦП.
- **Условия эффективности** — локальность данных и кода в пространстве-времени.

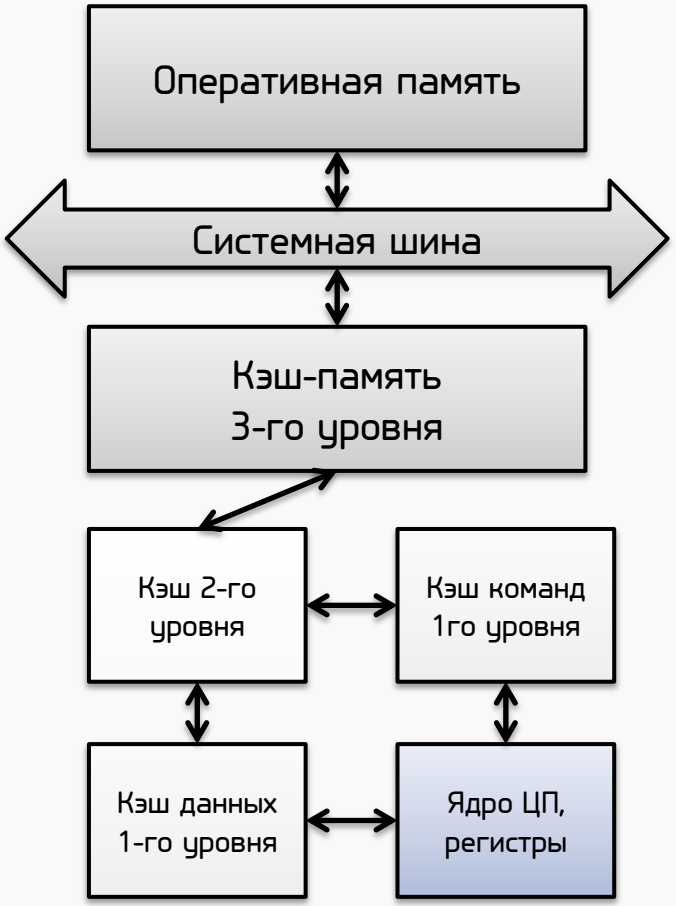

При подготовке сл. 54 – 55, 57 – 62 и Прил. Д использованы материалы доклада А.В. Петрова на конференции *DEV Labs C++* 2013.

Кэш-память в архитектуре современных ЭВМ: что делать?

- Обеспечивать **локальность данных и команд** в пространстве и времени:
  - совместно хранить совместно используемые данные или команды;
  - не нарушать эмпирические правила написания эффективного кода.
- Обеспечивать **эффективность загрузки** общей (L2, L3) и раздельной кэш-памяти данных (L1d) и команд (L1i):
  - полагаться на оптимизирующие возможности компилятора;
  - помогать компилятору в процессе написания кода.
- Знать **основы организации** аппаратного обеспечения.
- Экспериментировать!

Эффективный обход двумерных массивов

- Простейшим способом повышения эффективности работы с двумерным массивом является **отказ от его обхода по столбцам в пользу обхода по строкам:**
  - для массивов, объем которых превышает размер (выделенной процессу) кэш-памяти данных самого верхнего уровня (напр., L2d), время инициализации по строкам приблизительно втрое меньше времени инициализации по столбцам вне зависимости от того, ведется ли запись в кэш-память или в оперативную память в обход нее (У. Дреппер, 2007).
- Дальнейшая оптимизация может быть связана с анализом и переработкой решаемой задачи в целях снижения частоты кэш-промахов или использования векторных инструкций процессора (SIMD — Single Instruction, Multiple Data).

Эффективный обход двумерных массивов: постановка задачи

- **Задача.** Рассчитать сумму столбцов заданной целочисленной матрицы. Оптимизировать найденное решение с точки зрения загрузки кэш-памяти данных.

Дано:

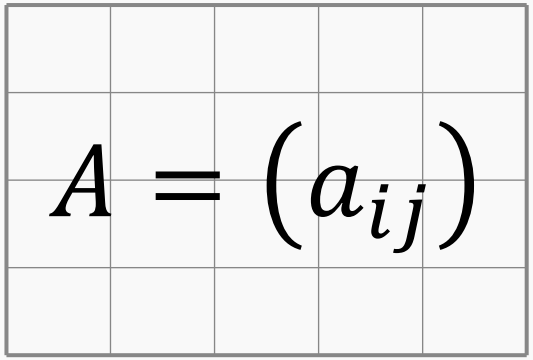

Найти:

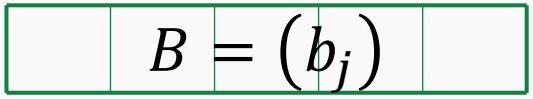

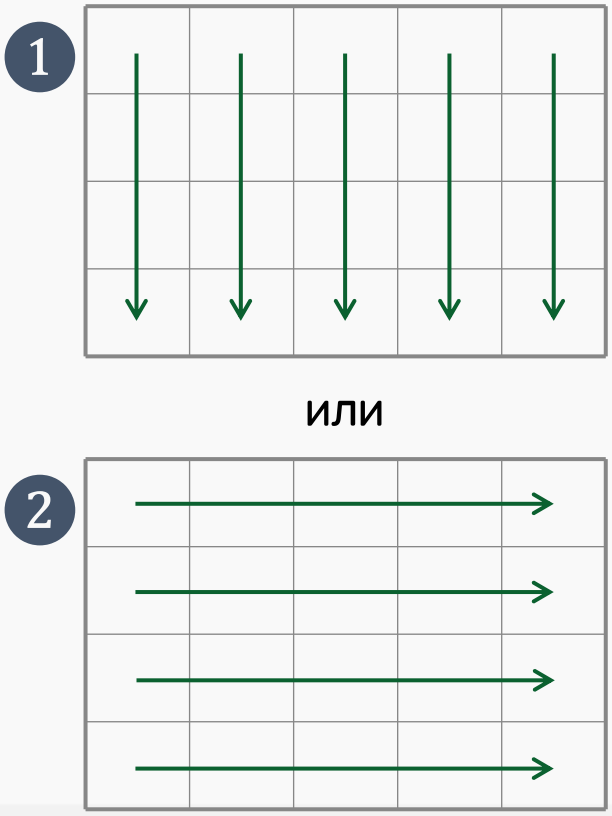

Эффективный обход двумерных массивов: анализ вариантов

- **Размерность задачи:**
  - **набор данных:** 2^8 x 2^8 (2^{16} элементов, 2^{18} байт);
  - **количество тестов:** 100;
  - **выбираемое время:** минимальное.
- **Инфраструктура тестирования:**
  - **x86:** Intel® Core™ i5 460M, 2533 МГц, L1d: 2 x 32 Кб;
  - **x86-64:** AMD® E-450, 1650 МГц, L1d: 2 x 32 Кб / ядро;
  - **ОС:** Ubuntu Linux 12.04 LTS; **компилятор:** GCC 4.8.x.
- **Порядок обеспечения независимости тестов —** 2-фазная программная инвалидация памяти L1d:
  - последовательная запись массива (10^6 элементов, ≈ 2^{22} байт);
  - рандомизированная модификация элементов.

Эффективный обход двумерных массивов: сравнительная эффективность

Эффективный обход двумерных массивов: результаты оптимизации

- Время решения задачи за счет оптимизации обхода данных (без применения SSE-расширений) **снижается в 1,8 – 2,4 раза**:
  - для ЦП **Intel x86**: от 1,5 до 2,2 раза;
  - для ЦП **AMD x86-64**: от 1,8 до 3,8 раза.
- При компиляции с флагами -O0, -O1 результат характеризуется **высокой повторяемостью** на ЦП с выбранной архитектурой (Intel x86 / AMD x86-64):
  - относительный рост эффективности колеблется в пределах **20 % – 25 %**.
- Применение векторных SIMD-инструкций из наборов команд SSE, SSE2, SSE3 позволяет улучшить полученный результат еще на **15 % – 20 %.**

Почему оптимизация работы с кэш-памятью того стоит?

- Несложная трансформация вычислительноемких фрагментов кода позволяет добиться **серьезного роста** скорости выполнения:
  - разбиение на квадраты (square blocking) и пр.
- **Причина — высокая «стоимость» кэш-промахов:**
  - на рис. — оценки для одного из ЦП Intel.

Что еще можно оптимизировать?

- **Предсказание переходов:**
  - устранение ветвлений;
  - развертывание (линеаризация) циклов;
  - встраивание функций (методов) и др.
- **Критические секции:**
  - устранение цепочек зависимости для внеочередного исполнения инструкций;
  - использование поразрядных операций, INC (++), DEC (--), векторизация (SIMD) и т.д.
- **Обращение к памяти:**
  - выполнение потоковых операций;
  - выравнивание и упаковка данных и пр.

Практикум №1

Постановка задачи

- Решить индивидуальную задачу №1 в соответствии с формальными требованиями.
- Для этого:
  - выполнить действия, указанные в письме-приглашении в систему автоматизированного тестирования задач (АСТС);
  - авторизоваться в АСТС и узнать в ней постановку задач.

Алексей Петров

Спасибо за внимание!

Приложения

Приложение А. Двумерные массивы и векторы векторов

- Двумерный массив следует отличать от вектора векторов, работа с которым:
  - предполагает двухступенчатую процедуру создания и удаления;
  - гарантирует смежность хранения данных только в пределах одной строки (аналогичная гарантия предоставляется и в отношении указателей на строки);
  - ведет к большей фрагментации памяти, но повышает вероятность успешного выделения в памяти непрерывных фрагментов (требование памяти объема $\sim N^2$ заменяется требованием памяти объема $\sim N$).
- **Многомерные массивы и векторы векторов (векторов…) являются различными структурами данных с разной дисциплиной использования.**

Двумерные массивы и векторы векторов: пример


```
// создание вектора векторов
int **v = (int**)malloc(N * sizeof(int*));
for(int i = 0; i < N; i++)
    // NB: в каждой строке значение M может быть разным
    v[i] = (int*)malloc(M * sizeof(int));

// ...

// удаление вектора векторов
for(int i = 0; i < N; i++)
    free(v[i]);
free(v);
```

Приложение Б. Выравнивание переменных составных типов

- Объекты составных типов языка C выравниваются в соответствии с характеристикой, **наибольшей** среди характеристик выравнивания всех своих элементов, которая в большинстве случаев не достигает длины линии кэш-памяти.
- Другими словами, даже при «подгоне» элементов структуры под линию L1d размещенный в ОЗУ объект может не обладать требуемым выравниванием.
- Принудительное выравнивание статически и динамически размещаемых структур выполняется аналогично выравниванию скалярных переменных и начальных элементов массивов:
  - GCC-атрибут aligned в определении типа или объекта данных;
  - функция posix_memalign.

Приложение B. Утилита pahole

- Самый доступный способ изучить физическое размещение элементов структуры в оперативной памяти и сопоставить их с загрузкой линий кэш-памяти L1d — **утилита pahole**, входящая в пакет dwarves.
- Использование утилиты pahole позволяет:
  - **проанализировать размещение** элементов структур относительно линий кэш-памяти данных;
  - **получить варианты** реорганизации структуры (параметр --reorganize).

Приложение Г.
Задача об умножении матриц (1 / 2)

- Классическим примером задачи, требующей неэффективного, с точки зрения архитектуры ЭВМ, обхода массива по столбцам, является задача об умножении матриц:

$$(AB)_{ij} = \sum_{k=0}^{N-1} a_{ik} b_{kj}$$

— имеющая следующее очевидное решение:

```
for(i = 0; i < N; i++)
    for(j = 0; j < N; j++)
        for(k = 0; k < N; k++)
            res[i][j] +=
                mul1[i][k] * mul2[k][j];
```

Задача об умножении матриц (2 / 2)

- Предварительное транспонирование второй матрицы повышает эффективность решения в 4 раза (с 16,77 млн. до 3,92 млн. циклов ЦП Intel Core 2 с внутренней частотой 2666МГц; У. Дреппер, 2007). Математически:

$$(AB)_{ij} = \sum_{k=0}^{N-1} a_{ik} b_{jk}^{T}$$

- На языке C:

```
double tmp[N][N];
for(i = 0; i < N; i++)
    for(j = 0; j < N; j++) tmp[i][j] = mul2[j][i];
for(i = 0; i < N; i++)
    for(j = 0; j < N; j++)
        for(k = 0; k < N; k++)
            res[i][j] += mul1[i][k] * tmp[j][k];
```

Приложение Д. Эффективный обход массивов: эффективность оптимизации